FLIGHT

E-Commerce verstehen.
Entscheidungen rechnen.
KI gezielt einsetzen.



Amit Steinberg
Hamburg
Oktober 2026

Business und Data Science anhand einer Online-Kundenreise. Ausführbare Methoden, interaktive Visualisierungen und dokumentierte Grenzen.

Die Leitfrage: Welcher nächste Schritt schafft Wert?

Der Kontext
Anna kauft von zu Hause in einem Onlineshop. Sie sucht eine kompakte Kaffeemaschine und möchte höchstens 150 Euro ausgeben.

Die geschäftliche Verbindung
Gute Treffer und Empfehlungen reichen allein nicht. Beitrag, zusätzliche Marketingwirkung, Retouren, Bestand und Service bestimmen den wirtschaftlichen Wert.

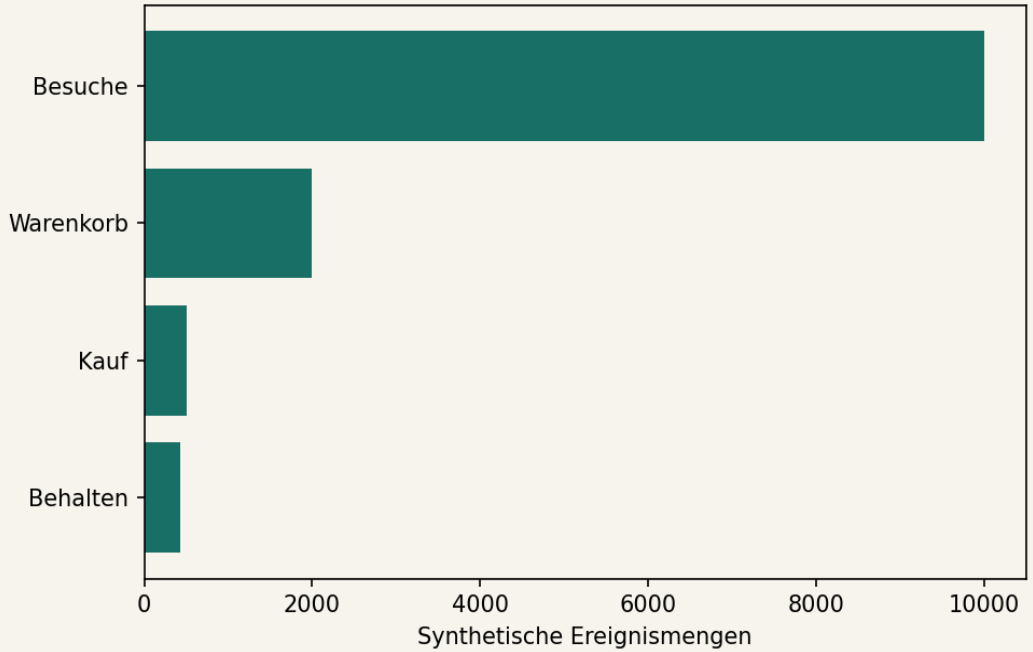
Der technische Anspruch
Das Portfolio trennt nachvollziehbare Simulationen, trainierbare Modelle und echte Messprotokolle. Eine beeindruckende Architektur braucht prüfbare Aussagen.

Architektur: Signale, Modelle und Entscheidungen

Datenschicht
Artikelkontakte, Sitzungen, Katalogattribute und Behandlungskontrollen bleiben nach Quelle getrennt.

Modellebene
Retrieval und Empfehlungen liefern Kandidaten. Kostenrechnung und Constraints übersetzen sie in Entscheidungen.

Ausführung und Rückkopplung
Ein fester Workflow bereitet einen Vorschlag vor. Das Team prüft die Entscheidung und misst die Wirkung.



Die Grafik zeigt ein synthetisches Funnelbeispiel. Sie ist kein gemessener Umsatz- oder Kausalnachweis.

01 / Business: Ein Onlineshop als System

Die Situation
Finden, Empfehlen, Rechnen, Rabatt entscheiden, Abstimmen und Prüfen sind sechs verbundene Entscheidungen.

Die Managemententscheidung
Funnelbrüche werden nicht automatisch durch mehr Werbebudget behoben. Eine gemeinsame Kennzahlenschicht verhindert widersprüchliche Definitionen.

Warum dieser Bereich zählt
Ein Onlinehändler optimiert nicht nur Klicks. Produktsuche, Kaufabsicht, Warenkorb, Retouren und Marketingkosten wirken auf denselben Beitrag.

Kaffeepause: Ein Klick ist ein Anfang. Der CFO akzeptiert ihn leider nicht als Überweisung.

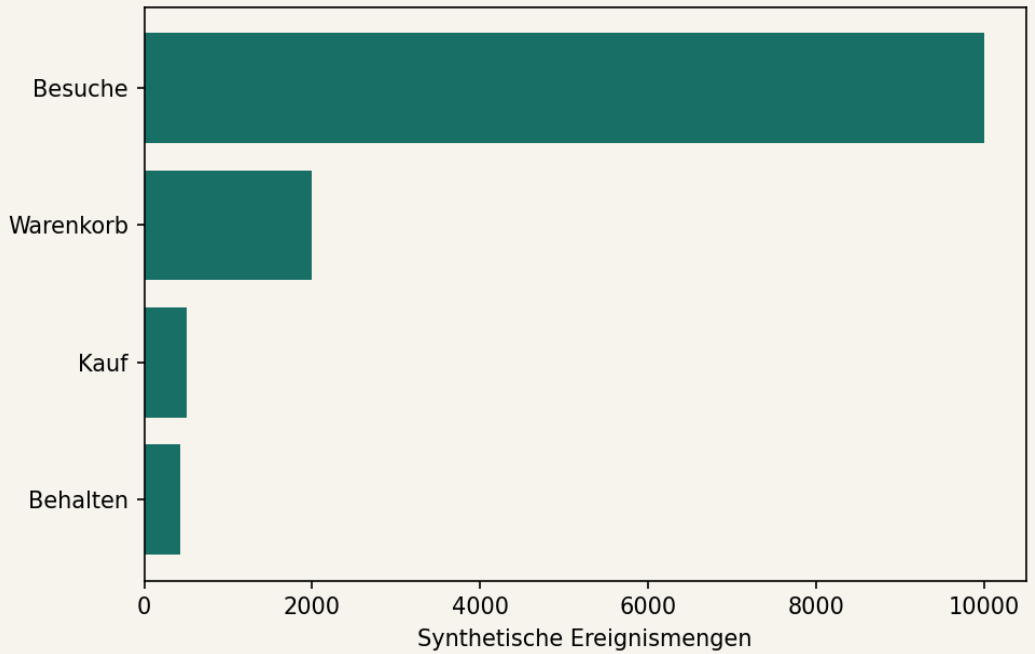
01 / Technik: E-Commerce als Entscheidungssystem

Methode

Die Architektur trennt Retrieval, Ranking, Entscheidungspolitik und Ausführung. Ein Feature-/Kennzahlenvertrag definiert Ereigniszeit, Identitäten und verfügbare Informationen. Ein Sprachmodell ist eine zusätzliche Komponente für Sprache und Werkzeugkoordination.

Interpretation der Grafik

Die Funnelzahlen unten sind ein Szenario. Verbindungen zeigen Mengenflüsse und keine Ursache-Wirkungs-Beweise.



Abbildungen aus reproduzierbaren Python-Berechnungen. Toy- und Szenariodaten sind keine trainierten Modellbeweise.

01 / Evidenz und nächster Versuch

So messen wir Qualität
Beitrag je Besuch und inkrementeller Beitrag; außerdem Sucherfolg, Retouren, Service und Laufzeit.

Der nächste fachliche Versuch
Ein gemeinsamer Eventvertrag verbindet session_id, item_id, event_time und action. Reale Kosten werden separat versioniert zugeordnet.

Aussagegrenze
Die Funnelzahlen unten sind ein Szenario. Verbindungen zeigen Mengenflüsse und keine Ursache-Wirkungs-Beweise.

Ziel: Eine andere Fachperson kann Daten, Rechenweg und Schlussfolgerung getrennt prüfen.

02 / Business: Anna formuliert ihren Suchwunsch

Die Situation
Suchbegriffe, Bild und Produktattribute liefern unterschiedliche Evidenz. Budget und Verfügbarkeit begrenzen die Kandidaten.

Die Managemententscheidung
Ein Treffer darf sprachlich ähnlich sein und trotzdem fachlich falsch. Deshalb harte Filter, Relevanzlabels und Fehleranalyse gemeinsam betrachten.

Warum dieser Bereich zählt
Der Suchwunsch muss zum Katalog passen. Harte Einschränkungen wie Preis, Bestand oder Größe gehören zusätzlich zur Ähnlichkeitssuche.

Kaffeepause: Anna sucht eine Maschine. Sie möchte nicht erst den exakten Datenbankbezeichner heiraten.

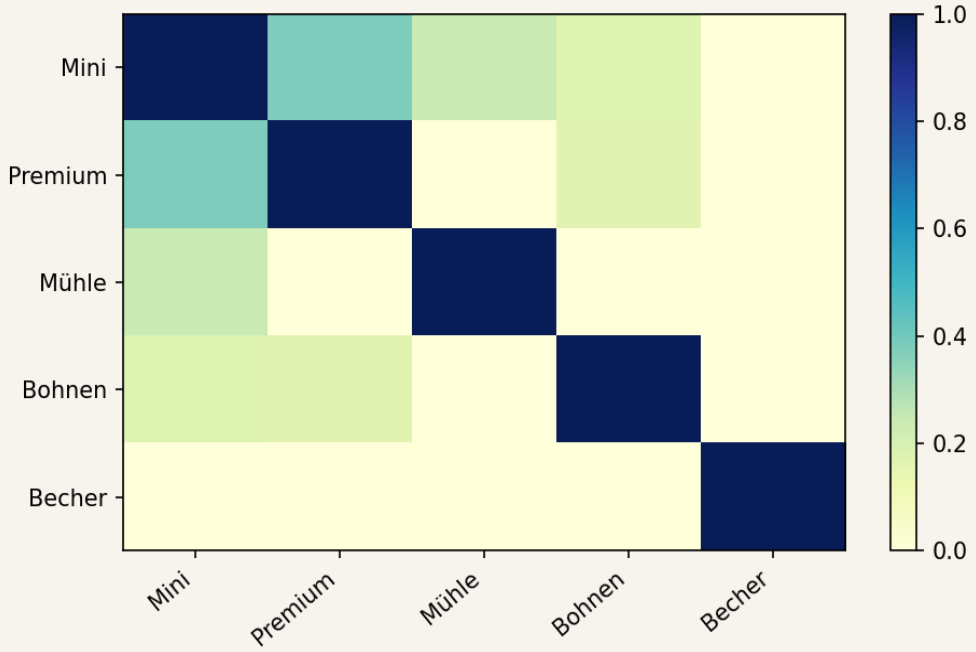
02 / Technik: Semantische und multimodale Produktsuche

Methode

Ein Bi-Encoder erzeugt normalisierte Vektoren. Kosinusähnlichkeit liefert Kandidaten; ein Reranker kann Anfrage und Artikel gemeinsam bewerten. Sentence Transformers verarbeiten Text. CLIP bildet Text und Bilder in einen gemeinsamen Raum ab. Ein Diffusionsmodell erzeugt dagegen neue Bilder.

Interpretation der Grafik

Die laufende Visualisierung nutzt echte TF-IDF-Vektoren auf einem synthetischen Minikatalog. Sie ist keine Messung eines Sentence-Transformer- oder CLIP-Modells.



Abbildungen aus reproduzierbaren Python-Berechnungen. Toy- und Szenariodaten sind keine trainierten Modellbeweise.

02 / Evidenz und nächster Versuch

So messen wir Qualität
NDCG für Suchrelevanz, Recall der Kandidaten, Latenz und Fehler bei harten Filtern; Cold-Start-Qualität für neue Artikel.

Der nächste fachliche Versuch
Im Suchstudio lassen sich echte Sentence-Transformer- und CLIP-Gewichte optional laden. ESCI liefert separat Relevanzlabels; neue Bilder sind kein Beleg für Produktmerkmale.

Aussagegrenze
Die laufende Visualisierung nutzt echte TF-IDF-Vektoren auf einem synthetischen Minikatalog. Sie ist keine Messung eines Sentence-Transformer- oder CLIP-Modells.

Ziel: Eine andere Fachperson kann Daten, Rechenweg und Schlussfolgerung getrennt prüfen.

03 / Business: Die nächste Produktempfehlung

Die Situation
Eine alternative Maschine hilft beim Vergleichen. Eine Mühle ergänzt den Einkauf. Die Reihenfolge der Artikelkontakte kann kurzfristige Kaufabsicht zeigen.

Die Managemententscheidung
Ein komplexes Modell muss gegen Popularität, Übergänge und ItemKNN gewinnen. Wiederholte Käufe und kalte Zielartikel beeinflussen den Vergleich.

Warum dieser Bereich zählt
Aktuelle Absicht und langfristige Ähnlichkeit sind verschiedene Signale. Kandidaten müssen nützlich sein, bevor Marge, Verfügbarkeit und Kontaktregeln die Reihenfolge verändern.

Kaffeepause: Ein größerer Transformer ist beeindruckend. Ein fair gewonnener Vergleich ist beeindruckender.

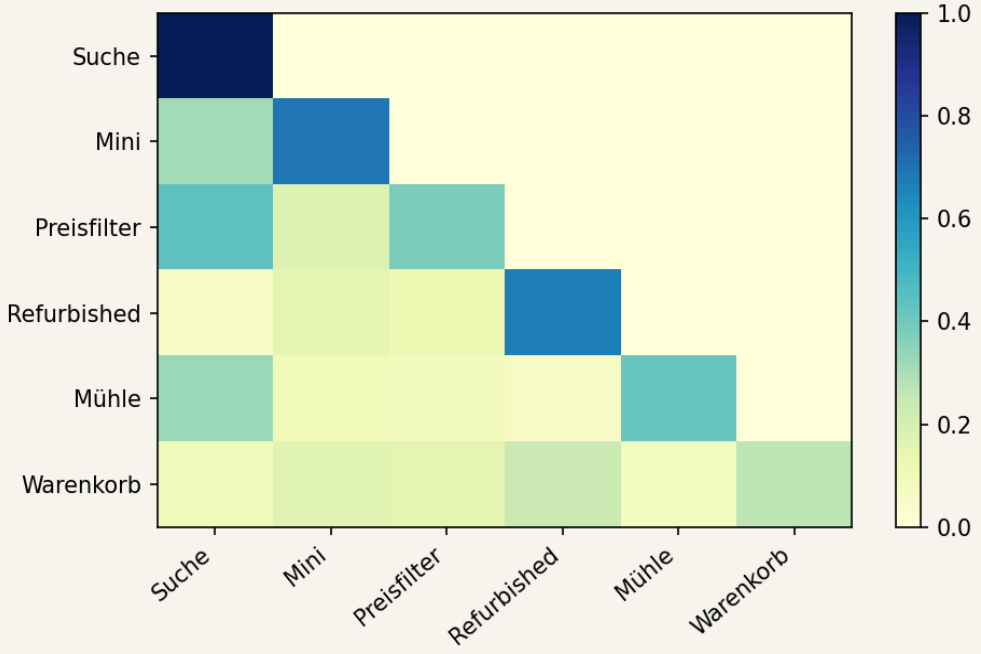
03 / Technik: Transformer, Graph und Ranking im Zusammenspiel

Methode

Attention berechnet softmax(Q K^T / sqrt(d) + Maske). BERT4Rec rekonstruiert maskierte Artikel mit bidirektionaler Attention. SASRec sagt mit kausaler Attention nachfolgende Artikel voraus. LightGCN propagiert Embeddings über den bipartiten User-Item-Graphen und lernt mit BPR: -log sigmoid(s_pos - s_neg), ergänzt um Regularisierung. Ein zweistufiges System kann Kandidaten aus mehreren Verfahren zusammenführen und neu sortieren.

Interpretation der Grafik

Die Attention-Grafik ist eine vollständig deklarierte Toy-Rechnung aus synthetischen Q/K-Vektoren. Sie stammt nicht aus einem trainierten BERT4Rec. Der Graph ist ein Beispielnetz.



Abbildungen aus reproduzierbaren Python-Berechnungen. Toy- und Szenariodaten sind keine trainierten Modellbeweise.

03 / Evidenz und nächster Versuch

So messen wir Qualität
Recall@K misst Treffer, NDCG@K belohnt frühe Treffer. Kandidatenprotokoll, kalte Zielartikel und wiederholte Käufe müssen dokumentiert werden.

Der nächste fachliche Versuch
Trainiere alle sechs implementierten Verfahren im Trainingslabor. Vergleiche sie zeitlich getrennt gegen Popularität, ItemKNN und Markov. Hyperparameter nur auf einem zusätzlichen Validierungsset auswählen.

Aussagegrenze
Die Attention-Grafik ist eine vollständig deklarierte Toy-Rechnung aus synthetischen Q/K-Vektoren. Sie stammt nicht aus einem trainierten BERT4Rec. Der Graph ist ein Beispielnetz.

Ziel: Eine andere Fachperson kann Daten, Rechenweg und Schlussfolgerung getrennt prüfen.

04 / Business: Was von einer Bestellung übrig bleibt

Die Situation
Bei einer separaten 100-Euro-Beispielbestellung gehen 50 Euro Ware, 6 Euro Abwicklung, 8 Euro Retourenreserve und 12 Euro Werbung ab. Es bleiben 24 Euro.

Die Managemententscheidung
Ein Rabatt von 10 Euro senkt diesen Beitrag auf 14 Euro. Das beweist noch nicht, ob zusätzliche Verkäufe den Rabatt rechtfertigen. Fixkosten fehlen.

Warum dieser Bereich zählt
Die Zielgröße muss zur Entscheidung passen. Umsatzoptimierung kann Rabatte, teure Retouren oder geringe Margen begünstigen.

Kaffeepause: Mehr Umsatz und weniger Geld: ein Klassiker, den niemand im Controlling nachbestellen möchte.

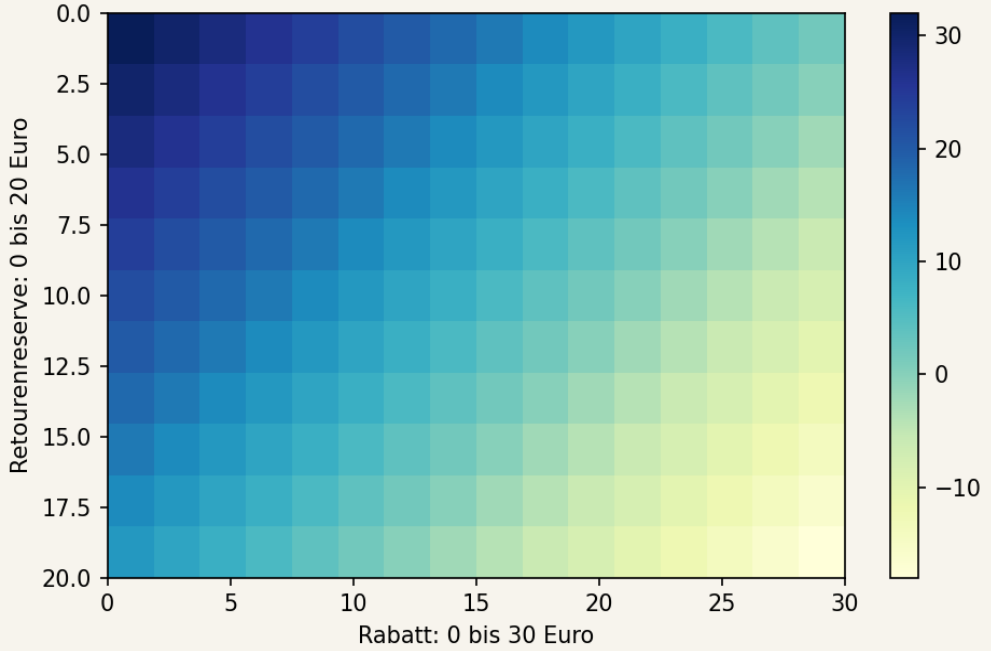
04 / Technik: Deckungsbeitrag, Preis und wirtschaftliches Ranking

Methode

Eine Entscheidungspolitik kombiniert kalibrierte Kaufwahrscheinlichkeit mit erwartetem Beitrag und Nebenbedingungen. Preiselastizität benötigt geeignete Variation; beobachtete Preise sind oft endogen. SHAP kann Modellbeiträge erklären, beweist aber keine kausale Wirkung.

Interpretation der Grafik

Die Sensitivitätsfläche ist eine Kostenrechnung unter Annahmen. Sie schätzt keine Preiselastizität und keine Zahlungsbereitschaft.



Abbildungen aus reproduzierbaren Python-Berechnungen. Toy- und Szenariodaten sind keine trainierten Modellbeweise.

04 / Evidenz und nächster Versuch

So messen wir Qualität
Erwarteter DB je Exposition, realisierter DB nach Retouren, Budget, Verfügbarkeit und Servicefolgen. Fixkosten ausdrücklich separat betrachten.

Der nächste fachliche Versuch
Nutze randomisierte Preis-/Angebotstests, sofern betrieblich geeignet. Sonst Identifikationsannahmen offenlegen. Prüfe Kalibrierung und Stabilität vor einer wertbasierten Rangfolge.

Aussagegrenze
Die Sensitivitätsfläche ist eine Kostenrechnung unter Annahmen. Sie schätzt keine Preiselastizität und keine Zahlungsbereitschaft.

Ziel: Eine andere Fachperson kann Daten, Rechenweg und Schlussfolgerung getrennt prüfen.

05 / Business: Wen sollte Marketing kontaktieren?

Die Situation
Fall A: Kaufchance 60 auf 62 Prozent. Fall B: 10 auf 25 Prozent. Bei 40 Euro Beitrag, 10 Euro Gutschein und 0,20 Euro Kontaktkosten ergeben sich -5,60 und +3,30 Euro Zusatzbeitrag.

Die Managemententscheidung
Der Gutschein wird bei allen behandelten Käufen bezahlt, auch wenn sie ohnehin stattgefunden hätten. Ein Propensity-Ranking allein berücksichtigt diesen Mitnahmeeffekt nicht.

Warum dieser Bereich zählt
Ein Angebot soll zusätzliche Wirkung erzielen. Der wahrscheinlichste Käufer ist nicht zwingend der beste Empfänger eines Gutscheins.

Kaffeepause: Rabatte für sichere Käufer sind die teuerste Form der Höflichkeit.

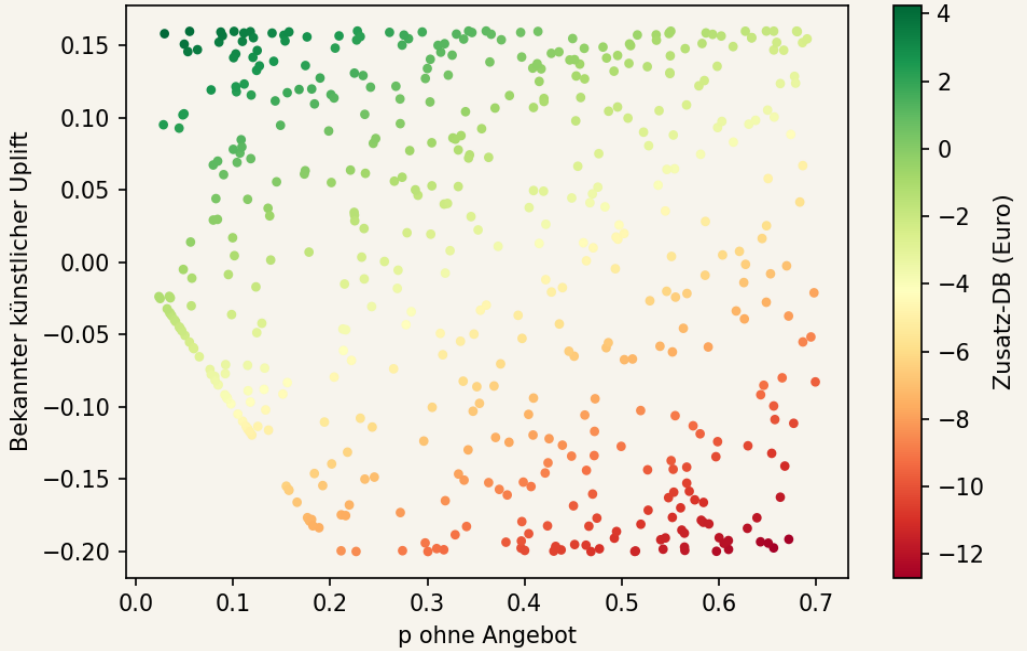
05 / Technik: Uplift und kausale Marketingentscheidungen

Methode

Ein T-Learner schätzt mu1(x) und mu0(x) getrennt. Ihr Unterschied ist geschätzte Heterogenität. Cross-Fitting und doubly robust Schätzung sind mögliche Weiterentwicklungen, hier nicht implementiert. Evaluation auf zurückgehaltenen randomisierten Daten per IPW und Upliftkurve.

Interpretation der Grafik

Das Streudiagramm zeigt bekannte Effekte einer künstlichen Population. Criteo untersucht Werbung, nicht die Gutscheine dieses Shops. Ein Präfix ohne Kontrollgruppe wurde korrekt abgewiesen.



Abbildungen aus reproduzierbaren Python-Berechnungen. Toy- und Szenariodaten sind keine trainierten Modellbeweise.

05 / Evidenz und nächster Versuch

So messen wir Qualität
AUUC oberhalb Zufall, kalibrierte Gruppenwirkungen und inkrementeller Beitrag nach Kontakt- und Gutscheinkosten. Individuelle Effekte bleiben unbeobachtbar.

Der nächste fachliche Versuch
Im Marketinglabor wird ein T-Learner tatsächlich trainiert, wenn geeignete Treatment-/Kontrolldaten vorliegen. exposure ist post-treatment und darf nicht als Zuweisung oder Eingangsfeature dienen.

Aussagegrenze
Das Streudiagramm zeigt bekannte Effekte einer künstlichen Population. Criteo untersucht Werbung, nicht die Gutscheine dieses Shops. Ein Präfix ohne Kontrollgruppe wurde korrekt abgewiesen.

Ziel: Eine andere Fachperson kann Daten, Rechenweg und Schlussfolgerung getrennt prüfen.

06 / Business: Das Onlineversprechen braucht bestätigte Fakten

Die Situation
180 Stück Lagerbestand treffen auf 40 Stück angenommenen Tagesbedarf und sieben Tage Lieferzeit. Es entsteht eine rechnerische Lücke von 100 Stück.

Die Managemententscheidung
Das Modell kann einen Bestandsbedarf berechnen. Einen individuellen Zustelltag darf das Sprachmodell daraus nicht erfinden. Einkauf und Service bestätigen die operativen Fakten.

Warum dieser Bereich zählt
Onlineversprechen hängen von Beständen und bestätigten Lieferinformationen ab. Ein Agent kann Informationen koordinieren; das Unternehmen trägt weiterhin die Verantwortung für Aktionen.

Kaffeepause: Der Agent darf vorbereiten. Eine Yacht als Kulanz braucht immer noch eine sehr gute Erklärung.

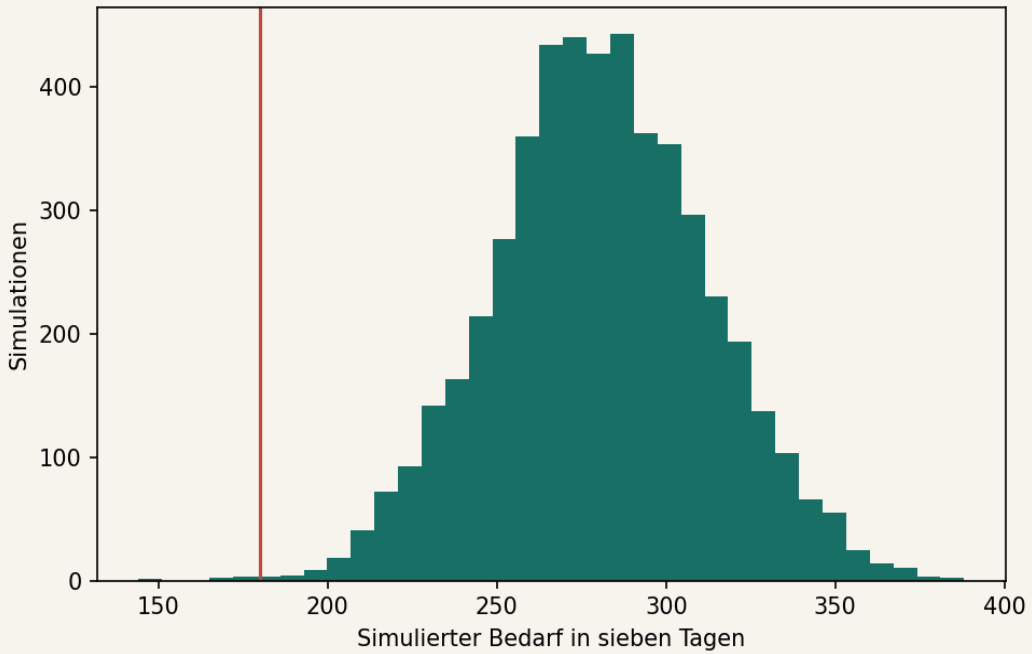
06 / Technik: AI Agents, RAG und operative Planung

Methode

RAG verbindet Retrieval und belegten Kontext. Tool-Calling trennt strukturierte Werkzeuganfrage und Ausführung. Ein Agentenloop ergänzt Zustand, Abbruchbedingungen und begrenzte Rechte. Flight führt derzeit einen festen lokalen Workflow aus; optionale OpenAI-/Anthropic-APIs formulieren Textentwürfe.

Interpretation der Grafik

Bestandssimulation und Rollenablauf sind lokal. Kein ERP oder Kundensystem ist verbunden. Gemini, autonome Multi-Agent-Orchestrierung und lokale LLM-Server sind Architekturoptionen, nicht implementierte Laufzeit.



Abbildungen aus reproduzierbaren Python-Berechnungen. Toy- und Szenariodaten sind keine trainierten Modellbeweise.

06 / Evidenz und nächster Versuch

So messen wir Qualität
Korrektheit von Zahlen und Quellen, erfolgreiche Tool-Ausführung, Eskalationen, Antwortzeit, Kosten je gelöstem Vorgang und tatsächlich realisierter Nutzen.

Der nächste fachliche Versuch
Teste ChatGPT/OpenAI und Claude/Anthropic mit denselben belegten Aufgaben. Prüfe Tool-Argumente, Antworttreue und Kosten. Ein zweiter LLM-Prüfer ersetzt keinen Ground Truth.

Aussagegrenze
Bestandssimulation und Rollenablauf sind lokal. Kein ERP oder Kundensystem ist verbunden. Gemini, autonome Multi-Agent-Orchestrierung und lokale LLM-Server sind Architekturoptionen, nicht implementierte Laufzeit.

Ziel: Eine andere Fachperson kann Daten, Rechenweg und Schlussfolgerung getrennt prüfen.

07 / Business: Eine bessere Zahl ist noch kein Erfolg

Die Situation
25 statt 29 Käufe bei jeweils 1.000 Personen ergeben 0,4 Prozentpunkte Unterschied. Das approximative Intervall umfasst auch null.

Die Managemententscheidung
Eine größere Stichprobe verringert im Lehrbeispiel die Unsicherheit. Reale Tests benötigen Randomisierung, eine relevante Zielmetrik und einen vorab definierten Auswertungsplan.

Warum dieser Bereich zählt
Eine bessere Kennzahl kann durch Zufall oder den Markt entstehen. Erfolg braucht eine passende Gegenprobe und die wirtschaftlich richtige Zielgröße.

Kaffeepause: Das Konfetti wird erst bestellt, wenn der Unsicherheitsbereich mitfeiert.

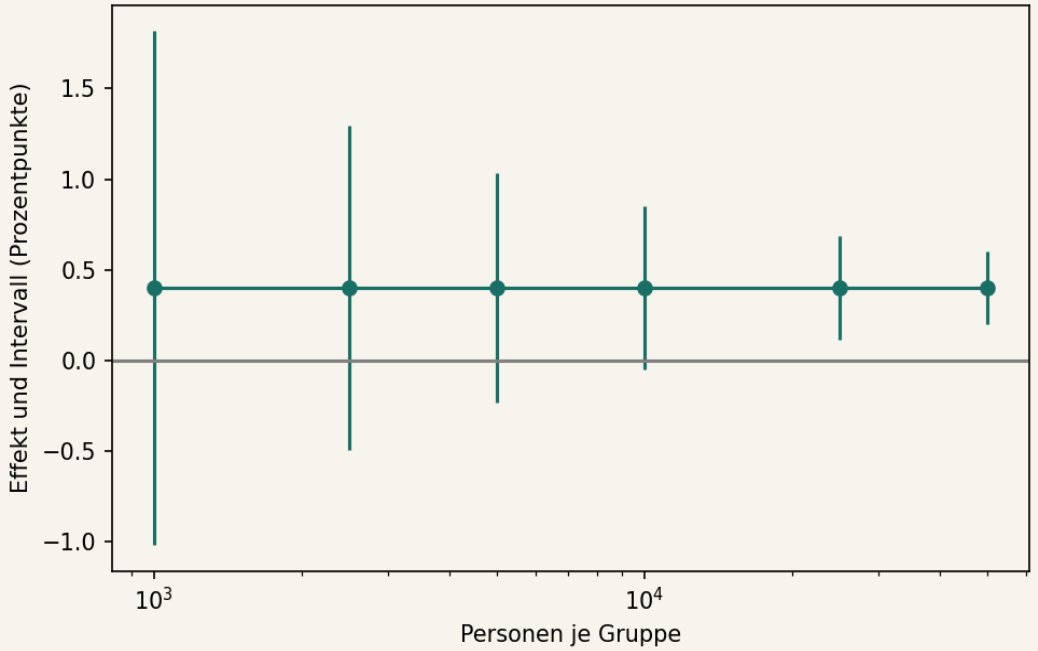
07 / Technik: Experimente, Ökonometrie und Unsicherheit

Methode

A/B-Tests nutzen Randomisierung.
Difference-in-Differences benötigt insbesondere parallele unbehandelte Trends. OLS allein schafft keine Kausalität.
Mehrfachtests, zeitliche Abhängigkeit und Interferenz können Standardfehler und Interpretation verändern.

Interpretation der Grafik

Die Intervallgrafik basiert auf erfundenen festen Kaufraten, nicht auf einer erhobenen Studie. Wald-Intervalle sind eine Approximation.



Abbildungen aus reproduzierbaren Python-Berechnungen. Toy- und Szenariodaten sind keine trainierten Modellbeweise.

07 / Evidenz und nächster Versuch

So messen wir Qualität
Effekt mit Intervall, minimale relevante Wirkung, Stichprobenumfang, DB und Nebenmetriken. Ein statistisch positiver Effekt kann wirtschaftlich unbedeutend sein.

Der nächste fachliche Versuch
Definiere Metrik, Randomisierungseinheit, Horizont und Auswertung vor dem Start. Das Evidenzstudio enthält eine separate OLS-/DiD-Auswertung mit HC3- oder Cluster-Standardfehlern.

Aussagegrenze
Die Intervallgrafik basiert auf erfundenen festen Kaufraten, nicht auf einer erhobenen Studie. Wald-Intervalle sind eine Approximation.

Ziel: Eine andere Fachperson kann Daten, Rechenweg und Schlussfolgerung getrennt prüfen.

08 / Business: Was der Projektstand tatsächlich belegt

Die Situation
Klassische Modelle und kompakte neuronale Modelle sind implementiert. Die lokale Testsuite prüft Datenadapter, Rechenwege, Modellpfade und Oberfläche.

Die Managemententscheidung
Ein kleiner Amazon-Präfixtest erzielte noch keinen Top-10-Treffer auf den warmen Testfällen. Ein Criteo-Präfix ohne Kontrollgruppe wurde abgewiesen. Beides bleibt dokumentiert.

Warum dieser Bereich zählt
Eine Demo wird zum belastbaren Portfolio, wenn eine andere Person die Schritte wiederholen und Grenzen erkennen kann.

Kaffeepause: Die ehrlich dokumentierte Null ist nützlicher als eine dekorativ erfundene Eins.

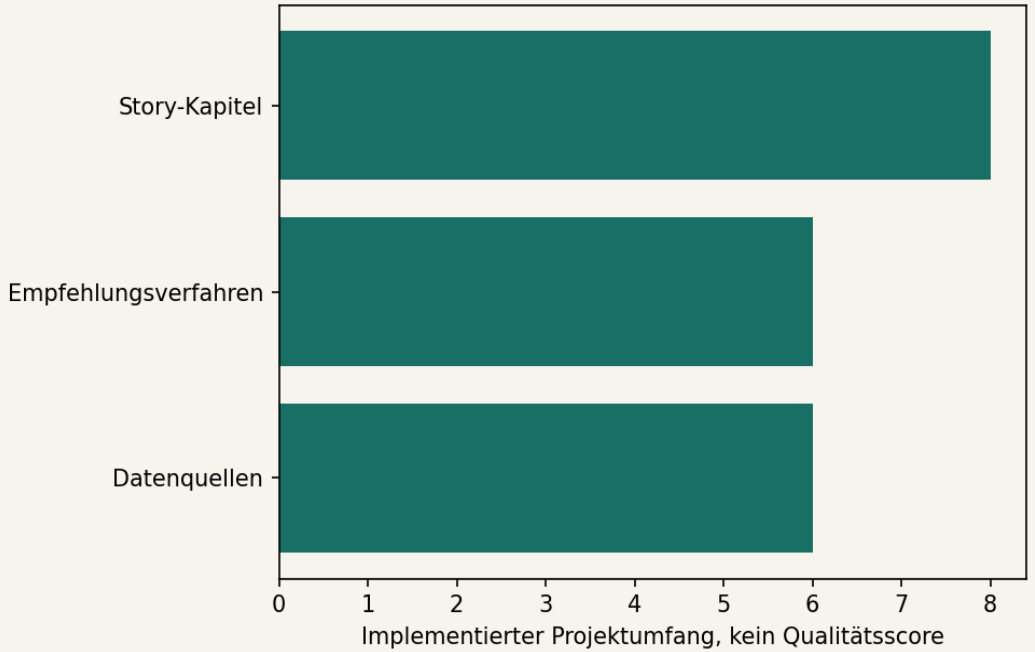
08 / Technik: MLOps, Datenverträge und glaubwürdige Evidenz

Methode

Zeitlicher Split, Trainingsvokabular und unveränderte Testdaten verhindern typische Leakage-Fehler. Laufprotokolle enthalten Fingerprints, Seed, Kandidatenraum und Zeiten. JSON/NPZ/state_dict werden getrennt von der Oberfläche exportiert. CI prüft Daten-, Modell- und GUI-Verträge.

Interpretation der Grafik

Aktuell kein nachgewiesener kommerzieller Effekt. Der kleine Amazon-Präfixtest erreichte keinen Top-10-Treffer auf den warmen Testzielen. Das ist ein Entwicklungsbefund und kein allgemeines Modellurteil.



Abbildungen aus reproduzierbaren Python-Berechnungen. Toy- und Szenariodaten sind keine trainierten Modellbeweise.

08 / Evidenz und nächster Versuch

So messen wir Qualität
Reproduzierbarkeit, Datenqualität, Abdeckung, Drift, Laufzeit und Kosten. Produktionswirkung wird gesondert online gemessen.

Der nächste fachliche Versuch
Nächster Schritt: repräsentativer Datenbestand, zusätzliches Validierungsset, größere Tests und begrenzter Onlinepilot. Öffentlich verfügbare Quellen bleiben getrennte Benchmarks.

Aussagegrenze
Aktuell kein nachgewiesener kommerzieller Effekt. Der kleine Amazon-Präfixtest erreichte keinen Top-10-Treffer auf den warmen Testzielen. Das ist ein Entwicklungsbefund und kein allgemeines Modellurteil.

Ziel: Eine andere Fachperson kann Daten, Rechenweg und Schlussfolgerung getrennt prüfen.

BERT4Rec und SASRec: zwei Trainingsfragen

Aspekt	BERT4Rec-artig	SASRec-artig
Aufgabe	Maskierten Artikel rekonstruieren	Nächsten Artikel aus Vergangenheit vorhersagen
Informationsfluss	Bidirektionale Attention im Trainingsfenster	Kausale Attention mit Dreiecksmaske
Flight-Implementierung	Kompakter Transformer; Einzelmaskenrekonstruktion	Kompakter Transformer; nächste Artikel
Gemeinsame Prüfung	Trainingsvokabular und unveränderte Testfälle	Vollkatalog-Ranking und kalte Ziele separat

Die oben gezeigte Attention stammt aus expliziten Toy-Q/K-Vektoren. Sie erklärt Softmax und Maskierung, nicht die intern gelernte Begründung eines echten Modells.

LightGCN: Beziehungen nutzen, Vergleiche fair halten

Repräsentation
Nutzer und Artikel bilden zwei Knotentypen. Interaktionen sind Kanten. Die normalisierte Nachbarschaft verbreitet Embeddings über mehrere Schichten.

Lernziel
BPR bevorzugt einen beobachteten gegenüber einem negativen Artikel. Im Projekt entstehen negative Artikel ausschließlich aus dem Trainingskatalog.

Flight und Grenzen
Die Implementierung mittelt propagierte Schichten. Zur Sessioninferenz werden historische Itemvektoren gemittelt. Das ist ein kompakter Versuchsaufbau, keine paper-exakte Reproduktion oder Produktionsskalierung.

Hybrides Retrieval und Reranking

Stufe	Konkrete Aufgabe	Qualitätsprüfung
Kandidaten	Lexikalische, semantische und kollaborative Treffer sammeln	Recall vor Reranking
Filter	Preis, Bestand, Markt und Artikelregeln prüfen	Verletzungen harter Regeln
Rangfolge	Relevanz und wirtschaftliche Ziele kombinieren	NDCG, Kalibrierung, Vielfalt
Entscheidung	Kosten, Budget und Kontaktregeln berücksichtigen	Inkrementeller Beitrag
Messung	Onlinewirkung gegen Kontrollbedingung prüfen	Effekt mit Unsicherheit

AI Agents: Arbeitsteilung statt Allzweckversprechen

Rolle	Daten/Werkzeug	Prüfbarer Beitrag
Finanzen	Kostenfunktion	Definierter DB, keine erfundene Marge
Einkauf	Bestandsfunktion	Meldebestand mit sichtbaren Annahmen
Service	Handbuch-Retrieval	Quellen für einen Antwortentwurf
Sprachmodell	Optional OpenAI-/Anthropic-API	Text aus bereitgestellten Fakten
Team	Fachliche Freigabe	Operative Entscheidung und spätere Messung

Aktuell läuft ein fester lokaler Workflow. Autonome Toolauswahl, ERP-Buchungen und ein Multi-Agent-Produktionsbetrieb sind nicht implementiert.

ChatGPT, Claude und die Auswahl eines Modells

Aufgaben statt pauschaler Rangliste
Beide Modellfamilien können für belegte Textentwürfe in Betracht kommen. Flight hat OpenAI- und Anthropic-API-Adapter; die Chatprodukte sind separate Zugänge.

Evaluationsset
Identische Fälle: richtige Zahl, korrekte Quelle, keine erfundene Lieferauskunft, brauchbarer Text. Dazu Latenz und Gesamtkosten erfassen.

Projektstatus
API-Adapter benötigen eigene serverseitige Schlüssel und wurden ohne Schlüssel nicht live getestet. Gemini, lokale LLM-Server und autonome Orchestrierung sind beschriebene Optionen.

Erklärbarkeit und Fehlersuche

Ein Modellbeitrag ist keine Ursache
SHAP oder ähnliche Verfahren können eine Vorhersage zerlegen. Eine Änderung eines Features muss im realen Geschäft nicht dieselbe Wirkung auslösen.

Was im Projekt sichtbar ist
Rangfolgen, Eingabegeschichte, Attention-Lehrrechnung, Vektorähnlichkeit, Kostenflächen und vollständige Protokolle helfen beim Nachvollziehen. Ein produktiver SHAP-Explainer ist hier nicht implementiert.

Fachliche Diagnose
Kalte Artikel, kurze Sessions, Retouren, Gruppenunterschiede und falsch verstandene Suchanfragen separat untersuchen. Aggregierte Scores können diese Fehler verdecken.

Ein KI-Pilot braucht eine Vollkostenrechnung

Kapazität
10.000 Vorgänge, 60 Prozent Nutzung und netto drei gesparte Minuten ergeben 300 Stunden pro Monat. Bei 45 Euro Stundenkosten entsprechen sie 13.500 Euro Kapazitätswert.

Realisierter Nutzen
Wenn 40 Prozent wirtschaftlich realisiert werden, bleiben 5.400 Euro vor API- und Betreuungskosten. Zeitgewinn allein ist keine Budgeteinsparung.

Kosten und Entscheidung
Tokenpreise sind im Rechner Eingabeannahmen, keine aktuellen Anbieterpreise. Betrieb, Prüfung und Implementierung müssen einbezogen werden. Der Pilot prüft Qualität und Nettoeffekt gemeinsam.

Die öffentlichen Quellen erfüllen getrennte Aufgaben

Quelle	Aufgabe	Wichtige Grenze
Retailrocket	Artikelkontakte und Transaktionen	Keine echten Shopmargen
REES46	Verhalten in weiteren Kategorien	Zugang und Lizenz prüfen
Amazon-M2	Nächster Artikel in einer Session	Eigenes Holdout-Protokoll
Amazon Reviews 2023	Reviews und Produktmetadaten	Reviews sind keine Klickhistorie
Amazon ESCI	Query-Produkt-Relevanz	Separates Suchranking
Criteo Uplift	Werbung vs. keine Werbung	Nichtuniform subsampelt; CC-BY-NC-SA-4.0

Reproduzierbarkeit und Betriebsreife

Ausführbare Bausteine
Streamlit-Story, technische Vertiefung in allen acht Kapiteln, Trainings-/Such-/Marketing-/Ökonometrie-Labore und KI-Business-Case. CPU-freundliche Einstiege und optionale neuronale Abhängigkeiten.

Messprotokolle
Zeitlicher 80/20-Split für Ereignisdaten, Trainingsvokabular, Vollkatalog-Auswertung, separat gezählte kalte Ziele. M2 nutzt einen eigenen Session-Holdout ohne globale Zeitgarantie.

Nächste belastbare Stufe
Repräsentative Daten, zusätzliche Validierung, größere Tests, Inferenzbudget und begrenztes Onlineexperiment. Kein kommerzieller Effekt wird aus Funktionstests abgeleitet.

Was dieses Portfolio im Gespräch zeigen soll

Business-Verständnis
Ziele, Kosten und Verantwortlichkeiten vor der Modellwahl definieren. Den zusätzlichen Beitrag statt nur Klicks oder Umsatz betrachten.

Data-Science-Verständnis
Repräsentationen und Lernziele unterscheiden, faire Kandidatenräume nutzen, Leakage vermeiden und Unsicherheit quantifizieren.

Umsetzung und Kommunikation
Trainierbaren Code, verständliche Online-Kundenreise, technische Grafiken und reproduzierbare Nachweise verbinden. Grenzen offen erklären statt fehlende Resultate zu dekorieren.

Amit Steinberg · Hamburg · Oktober 2026

Quellen und technische Lektüre

github.com/botsandbolts/Flight

arxiv.org/abs/1904.06690 (BERT4Rec)

arxiv.org/abs/1808.09781 (SASRec)

arxiv.org/abs/2002.02126 (LightGCN)

sbert.net (Sentence Transformers)

arxiv.org/abs/2103.00020 (CLIP)

huggingface.co/datasets/criteo/criteo-uplift

github.com/amazon-science/esci-data

amazon-reviews-2023.github.io

developers.openai.com/api/docs/guides/tools

platform.claude.com/docs/en/agents-and-tools/tool-use/how-tool-use-works